

Centro Universitário de Itajubá – FEPI

Curso de Sistemas de Informação

Projeto Semestral Definição do problema e base

PARTE I

Aluno: Vitor Faria, Rafael Junqueira, Ariel

Morais, Miguel Santos, Luciano Borges

Itajubá – MG

2026

1. Definição do Problema (Foco em IA)

1.1 Descrição do Problema Específico que a IA resolverá

O problema central é a **ineficiência na previsão de demanda diária**, que resulta em um índice de perdas entre 3% e 5% do volume total produzido. Atualmente, a padaria decide a quantidade de produção de forma empírica (intuição), sem considerar variáveis externas que afetam o comportamento do consumidor.

A IA resolverá este problema atuando como um **classificador preventivo**. O modelo analisará o cenário do dia (clima, dia da semana, feriado e categoria do produto) para classificar se uma determinada escala de produção resultará em **"Perda Crítica"** ou **"Venda Bem-Sucedida"**. Com essa classificação em mãos *antes* da produção iniciar, o gestor pode reduzir ou aumentar o volume produzido, atacando diretamente a causa raiz do desperdício.

1.2 Justificativa da Importância

A implementação de um modelo de classificação supervisionada permite:

- **Redução de Custos Operacionais:** Minimizar o descarte de matéria-prima e o uso desnecessário de mão de obra em lotes que não serão vendidos.
- **Otimização de Prateleira:** Garantir que os produtos disponíveis tenham maior probabilidade de saída, mantendo o estoque sempre fresco.
- **Sustentabilidade Alimentar:** Reduzir o impacto social e ambiental do descarte de alimentos perecíveis.

1.3 Definição da Variável Alvo (Target)

Para que a IA possa aprender, definimos uma variável alvo binária baseada no histórico de perdas da padaria:

- **Variável:** `Status_Perda`
- **Classe 0 (Sucesso):** Venda total ou sobra dentro da margem de segurança (até 3% da produção).
- **Classe 1 (Perda Crítica):** Perda superior a 5% da produção do item, exigindo intervenção no planejamento

2. Obtenção da Base de Dados

2.1 Origem e Fonte dos Dados

Devido à ausência de registros digitais estruturados na padaria objeto deste estudo (conforme detalhado na justificativa de impossibilidade técnica), optou-se pela utilização de uma **base de dados sintética aumentada**.

A base foi gerada via script Python, utilizando padrões estatísticos de consumo e desperdício de alimentos observados em repositórios de referência como o **Kaggle** e o **UCI Machine Learning Repository**. Para conferir realismo ao modelo, os dados foram correlacionados com

fatores externos reais através da biblioteca **holidays** (feriados brasileiros) e simulações de variáveis climáticas, garantindo que o comportamento da base mimetize um cenário comercial real.

- **Link da base de dados:**

<https://drive.google.com/file/d/1lQtXBGJv3Y-4-uku7ejz9eBO2-CEdIFI/view?usp=sharing>.

2.2 Descrição das Variáveis

A base de dados foi construída em total alinhamento com a modelagem lógica do sistema. As principais variáveis (colunas) são:

Variável	Tipo	Descrição	Origem (Modelagem)
id_produto	Inteiro	Identificador único do produto.	PRODUTO (id)
nome_produto	String	Nome do item (ex: Pão Francês, Bolo, Leite).	PRODUTO (nome)
preco_venda	Decimal	Valor de venda da unidade ou peso.	PRODUTO (precoVenda)
categoria	String	Classificação do item (Padaria ou Mercearia).	CATEGORIA (nome)
data_registro	Date	Data da produção e venda.	PERDA (dataRegistro)
qtd_produzida	Inteiro	Volume total fabricado no lote.	Atributo de Produção.
qtd_perdida	Inteiro	Quantidade que não foi vendida e resultou em perda.	PERDA (quantidadePerdida)

temperatura	Decimal	Temperatura média do dia (fator externo).	Variável de Contexto.
feriado	Booleano	Indica se a data é um feriado oficial.	Variável de Contexto.
status_perda	Binário	Variável Alvo (Target): 0 para perda normal e 1 para perda crítica (>5%).	Definição do Problema.

2.3 Identificação de Problemas no Dataset

Para cumprir o requisito de análise exploratória e pré-processamento, a base de dados foi propositalmente gerada com as seguintes inconsistências que serão tratadas futuramente:

1. **Dados Faltantes (Missing Values):** Aproximadamente 5% das entradas nas colunas `preco_venda` e `temperatura` possuem valores nulos (NaN), simulando falhas de registro humano ou de sensores.
2. **Inconsistências de Valores (Outliers):** Foram inseridos registros com `preco_venda` zerado e quantidades de perda negativas para testar a robustez dos algoritmos de limpeza.
3. **Desbalanceamento de Classes:** Como a perda crítica é um evento menos frequente que a venda normal, a base apresenta um desbalanceamento natural que exigirá técnicas específicas de avaliação de modelos.